

Metody segmentacji naczyń krwionośnych na obrazach dna oka

Jakub Harasymowicz
219354@student.pwr.edu.pl

Maciej Kinal
221358@student.pwr.edu.pl

Patryk Ząbkiewicz
221394@student.pwr.edu.pl

Streszczenie—W niniejszej pracy zostaje podjęta próba przetworzenia obrazów uzyskanych podczas badania dna oka, a dokładniej mówiąc – ich segmentacji za pomocą różnych metod. Ma to na celu wyodrębnienie naczyń krwionośnych, których nienaturalna ilość i rozmiar może wskazywać na chorobę zwaną *retinopatią cukrzycową*. Posegmentowane obrazy dna oka uwiadaczające naczynia krwionośne mogą stanowić jedną z cech, która może zostać wykorzystana w algorytmach uczenia maszynowego do automatyzacji detekcji retinopatii cukrzycowej, która z kolei stanowi globalny problem zdrowotny.

Index Terms—fundus image processing, fundus image segmentation, diabetic retinopathy

I. WPROWADZENIE

Jednym z powikłań trwającej długi okres czasu cukrzycy może być negatywnie oddziaływanie na małe naczynia krwionośne w siatkówce oka, prowadzące do choroby zwanej *retinopatią cukrzycową*. Choroba ta przebiega w kilku etapach zaawansowania, powodując różne dolegliwości wzroku, w najgorszych przypadkach wywołując nawet całkowitą ślepotę. Dotyczy to około 2,4 miliona przypadków na świecie, stawiając tym samym retinopatię na 5 miejscu, jeśli chodzi o przyczyny utraty wzroku u osób w wieku 25-75 lat [1].

Jedną z technik obrazowania, która umożliwia śledzenie rozwoju retinopatii jest obrazowanie dna oka (oftalmoskopia, fundoskopia). Obraz dna oka pozwala uwiadoczyć takie kliniczne zmiany jak mikrotętniaki (drobne czerwone okrągłe plamki), wysięki (nieregularne żółte plamki), wylewy do ciała szklistego. W najpóźniejszym stadium retinopatii cukrzycowej – retinopatii proliferacyjnej – może objawiać się także w zamykaniu naczyń oraz proliferacji, czyli powstawaniu nowych naczyń w znaczącej ilości [2].

Jako że duża ilość drobnych naczyń krwionośnych może wskazywać na retinopatię cukrzycową, informację tę można wykorzystać w automatyzacji rozpoznawania tej choroby. W tym celu, w niniejszej pracy zostanie przeprowadzone przetworzenie obrazów – segmentacja – mające na celu wyodrębnienie naczyń krwionośnych z obrazów dna oka.

II. MATERIAŁY I METODY

A. Baza obrazów

W projekcie wykorzystano ogólnodostępny zbiór DRIVE (Digital Retinal Images for Vessel Extraction) [3]. Zbiór ten zawiera 40 kolorowych obrazów dna oka, pochodzących od osób w wieku 31–86 lat. Każdy obraz ma wymiary 584x565 pikseli. Baza jest podzielona na zbiór uczący oraz treningowy,

gdzie każdy zawiera po 20 obrazów. Wśród tych obrazów 33 nie wykazują żadnych symptomów patologicznych, pozostałe 7 uwiadaczają oznaki charakterystyczne dla retinopatii cukrzycowej (3 znajdują się w zbiorze uczącym, a 4 są obecne w zbiorze testowym) [4].

B. Pre-processing

Wstępne przetworzenie obrazu wejściowego ma decydujące znaczenie dla kolejnych etapów – segmentacji, klasyfikacji obrazów, czy też na wydajność obliczeniową. Jak wspomniano w [6] różnego rodzaju operacje morfologiczne na obrazach, takie jak dylacja, erozja, opening, closing, transformacja top-hat, czy też techniki usuwające szum z obrazu jak np. *median filter* pozwalają uwydatnić pewne regiony, kształty, krawędzie, granice obrazu, co podnosi skuteczność algorytmów stosowanych w późniejszych krokach przetwarzania obrazu. (...fragment zostanie uzupełniony o techniki, które zostaną użyte w projekcie...)

C. Metody segmentacji

1) *Segmentacja progowa (ang. threshold segmentation)*: Ten rodzaj segmentacji polega na wyborze progu, powyżej którego wybrany piksel ustawiany zostaje na pierwszy plan (ang. *foreground*), a w przeciwnym razie na tło ((ang. *background*). Istotny w tym przypadku jest wybór metody progowania. Po wstępnym zapoznaniu się i przeanalizowaniu kilku dostępnych sposobów, wybrano adaptacyjne lokalne progowanie (ang. *local adaptive thresholding*). Metoda polega na podzieleniu obrazu na mniejsze części (okna) i wyliczeniu statystyk, takich jak średnia oraz mediana sąsiadujących pikseli, a następnie aktualizacji wartości progowej. W tym przypadku jednak zdecydowano się zastosować metodę zwaną *mean-C threshold*, w której występuje stała C . Różnica polega na tym, że piksele leżące w jednakowej okolicy są przypisywane do tła. Przykład algorytmu segmentacji metodą progową *mean-C* został przedstawiony w pracy [5]:

- 1) Obliczenie średniej wartości pikseli w oknie $N \times N$
- 2) Splot wartości pikseli obrazu ze średnią
- 3) Otrzymanie obrazu różnicowego poprzez odjęcie splotu od obrazu pierwotnego (po preprocessingu)
- 4) Nałożenie na obraz różnicowy progu ze stałą wartością C
- 5) Wyliczenie uzupełnienia otrzymanego obrazu

Do zastosowania algorytmu *mean-C* potrzebne jest wyliczenie dwóch wartości: stałej C oraz rozmiaru okna.

W obu przypadkach zostanie to zrobione empirycznie.

2) *Segmentacja za pomocą analizy skupisk*: Segmentacja za pomocą analizy skupisk (z ang. *clustering segmentation*) może bazować na algorytmie K-średnich, który kategoryzuje się jako jeden z nienadzorowanych algorytmów uczenia maszynowego. Ogólna koncepcja polega na tym, że punkty danych wejściowych klasyfikuje się na więcej niż jedną klasę w oparciu o odległość między każdym punktem i od punktu centralnego dla danej klasy zwanego centroidem. W ujęciu segmentacji obrazów algorytm przedstawia się następująco [6]:

- 1) Obliczyć histogram intensywności (rozkład intensywności)
- 2) Centroidy są inicjalizowane k -losowymi intensywnościami
- 3) Przypisać punkty do klastrów zależnie od ich odległości (najczęściej odległość Euklidesowa) od centroidów intensywności
- 4) Dla każdego klastra obliczyć nowy centroid
- 5) Punkty 3–4 powtarzać do osiągnięcia stałej wartości przynależności skupienia albo do osiągnięcia maksymalnej liczby iteracji zdefiniowanej przez użytkownika.

3) *Segmentacja wododziałowa* (ang. *watershed segmentation*): W tym algorytmie segmentacji cyfrowy obraz wejściowy interpretowany jest jako powierzchnia topograficzna. Obszar odpowiada zlewisku – czyli terenowi z którego wody opadowe spływają do wspólnego zbiornika wodnego. Linia rozgraniczająca tereny zlewisk jest zwana wododziałem. Amplituda gradientu intensywności pikseli (lub sama intensywność) stanowi wysokość terenu, natomiast linia rozgraniczająca (wododział) jest zawsze umiejscowiona na grzbiecie takiej funkcji. W przypadku obrazu cyfrowego obszary o małej intensywności tworzą terenowe „doliny”, zaś obszary o dużej intensywności – „wzniesienia”. [7] Obrazem wejściowym dla algorytmu segmentacji wododziałowej powinien być obraz gradientowy otrzymany z oryginalnego (np. obraz z gradacją stopni szarości). W segmentacji wododziałowej można wyróżnić kilka podejść [8]:

- 1) Podejście oparte o opad deszczu (ang. *rainfall*)
 - a) Z każdego piksela obliczana jest odległość do minimum lokalnego, która jest poprowadzona metodą schodzenia w dół czyli przeciwnie do kierunku lokalnego gradientu („wzniesienia”)
 - b) następnie do jednego takiego zlewiska zaliczane są wszystkie piksele, których droga prowadzi do tego samego minimum lokalnego („doliny”)
 - c) Kontury segmentowanych obiektów na obrazie są wyznaczane przez wododziały tworzące się między takimi zlewiskami
 - d) Obszary minimów mogą być „płaskie” (posiadają taką samą wartość na całym obszarze), jest to przeszkodą w identyfikacji, w takim przypadku pomocna okazuje się transformacja odległościowa (ang. *distance transform*)

- 2) Podejście oparte o zatapianie (ang. *sinking*)

- a) W obrazie znajdowane są minima lokalne do których przypisywane są zagłębienia w ukształtowaniu terenu (początkowe zlewiska Z)
- b) następnie zlewiska są porządkowane kolejno z rosnącym poziomem intensywności ($Z1, Z2, \dots, Z_n$)
- c) cały obraz jest stopniowo „zanurzany w wodzie”
- d) w miejscach w których zlewiska się stykają tworzone są kontury segmentowanych obiektów

III. WYNIKI

IV. PODSUMOWANIE

LITERATURA

- [1] R. Lee, T.Y. Wong, C. Sabanayagam, „Epidemiology of diabetic retinopathy, diabetic macular edema and related vision loss”, *Eye and Vision*, vol. 2 pp. 17, Wrzesień 2015.
- [2] M.I. Lopez-Galvez, F. Manco Lavado, J.C. Pastor, „Diabetic Retinopathy: An Overview”, *Handbook of Nutrition, Diet and the Eye*, pp. 41–51, 2014.
- [3] S. Tatiraju, A. Mehta, „Image Segmentation using k-means clustering, EM and Normalized Cuts”, vol. 1, pp. 1–7, 2008
- [4] R. GeethaRahmani, L. Balasubramanian, „Retinal blood vessel segmentation employing image processing and data mining techniques for computerized retinal image analysis”, vol. 36, pp. 102–118, 2016
- [5] J. Dash, N. Bhoi, „A thresholding based technique to extract retinal blood vessels from fundus images”, *Future Computing and Informatics Journal* vol. 2, pp. 103–109, 2017
- [6] G. Hassan, N. El-Bendary, A.E. Hassanien, A. Fahmy, A.M. Shueb, V. Snasel, „Retinal blood vessel segmentation approach based on mathematical morphology”, *Procedia Computer Science*, vol. 65, pp. 612–622, 2015.
- [7] M.S. Soundarya, T. Swathi, „Analysis of retinal vasculature by watershed segmentation and histogram analysis”, *International Journal of Engineering Trends and Technology (IJETT)* - volume 45 number 5, Marzec 2017.
- [8] K. Krawiec, „Przetwarzanie i rozpoznawanie obrazów”, 20 Kwiecień 2016.